Тема 1. Введение в структуры и алгоритмы обработки данных

Лекция 2

Классификация структур данных

Понятие структуры данных

Как было указано в предыдущей лекции, в процессе преобразования информации от постановки задачи до получения компьютерной программы выделяются два взаимосвязанных объекта – данные и алгоритм их преобразования. Основную информацию, относящуюся к понятию алгоритма, мы рассмотрели ранее. Уточним понятие данных.

ЭВМ в настоящее время приходится не только считывать и выполнять определенные алгоритмы, но и хранить значительные объемы информации, к которой нужно быстро обращаться. Эта информация в некотором смысле представляет собой абстракцию того или иного фрагмента реального мира и состоит из определенного множества данных, относящихся к какой-либо проблеме.

Независимо от содержания и сложности любые данные в памяти ЭВМ представляются последовательностью двоичных разрядов, или битов, а их значениями являются соответствующие двоичные числа. Данные, рассматриваемые в виде последовательности битов, имеют очень простую организацию или, другими словами, слабо структурированы. Для человека описывать и исследовать сколько-нибудь сложные данные в терминах последовательностей битов весьма неудобно. Более крупные и содержательные, чем бит, «строительные блоки» для организации произвольных данных получаются на основе понятия «структуры данного».

Данные – это значения или наборы значений, описывающие любую информацию, которую можно обработать на компьютере. В зависимости от назначения программы, данные могут иметь разный уровень сложности или организованности, начиная от самых простых (числа или символы) и

заканчивая достаточно сложными образованиями, включающими как сами элементы данных, так и информацию об их количестве и взаимосвязях между этими элементами. Модель организованности данных принято называть ***структурой данных*** (другими словами, *структура данных* в общем случае - множество элементов данных и множество связей между ними).

Пример. Т.к. данные – это некоторые сообщения, слова в некотором заданном алфавите, то

- число 123 – данное, представляющее собой слово в алфавите из десяти натуральных цифр;
- число 12,34 – данное, представляющее собой слово в алфавите из десяти натуральных цифр и десятичной запятой;
- текст "математика и информатика – нужные дисциплины", – данное в алфавите из символов русского языка и знаков препинания, включая пробел.

Текущее (то есть рассматриваемое в данный момент времени) состояние *данных* называют текущим *значением данных* или просто *значением.*

До разработки алгоритма (программы) необходимо выбрать оптимальную для реализации задачи структуру данных. На структуру данных влияет выбранный метод решения.

Различают следующие ***уровни представления структур данных***:

- абстрактный (математический) уровень;
- логический уровень;
- физический уровень.

Абстрактный уровень определяет характер организованности структуры данных. Организованность описывается математической моделью и может быть представлена множеством элементов, каждый из которых является значениями данных, и отношениями между ними, свойства которых определяют различные типы данных. ***Тип данных*** – это математическая модель организованности данных и различные операторы, определенные в рамках этой модели.

Логический уровень – представление структуры данных на языке программирования. Простейшие структуры, представляющие собой один элемент, определяются простыми типами. В языках программирования для переменных простого типа уже определены множества допустимых значений и набор допустимых операций. Определенные в языке программирования типы данных называют базовыми. Их характер организованности – простейший.

Составные структуры данных, представляющие собой совокупность простых структур и отношения между ними, могут быть определены программистом в виде структурных типов, таких как массив или структура (запись). В этом случае набор допустимых значений зависит от простых типов, на основе которых построена структура данных и ее типа. Множество допустимых операций и характер организованности определяется структурным типом. Так как рассмотренные составные структуры полностью определяются типами данных языка программирования, то их можно назвать базовыми типами данных.

Для других структур данных, например список, стек, очередь, дерево, таблица и др., нет соответствующих типов, определяющих организованность этих данных и допустимые операции. Такие структуры данных называются производными и реализуются непосредственно программистами. Одна и та же производная структура данных может быть реализована различными способами, но множество допустимых значений, набор допустимых операций и характер организованности остаются неизменными, так как это свойство самой структуры данных, а не способа её реализации.

Физический уровень – отображение на память ЭВМ информационного объекта в соответствии с логическим описанием. На этом уровне определяются область и объём памяти, необходимый для хранения экземпляра структуры данных, форматы и интерпретация внутреннего представления. Другими словами, понятие «*физическая структура данных*» отражает способ физического представления данных в памяти машины и называется еще структурой хранения, внутренней структурой или структурой памяти.

Классификация структур данных

Всю совокупность данных можно разделить на данные статической структуры и данные динамической структуры.

Данные статической структуры могут быть простыми и составными, они формируются из простых структур по определенному закону, взаимное расположение и взаимосвязь элементов структуры всегда остаются постоянными.

Данные динамической структуры – это данные, внутреннее строение которых формируется по определенному закону, но количество элементов, их взаиморасположение и взаимосвязи могут динамически изменяться во время выполнения программы.

Типы данных можно разделить на типы линейной структуры и типы нелинейной структуры.

Типы данных линейной структуры определяют список элементов, упорядоченных по положению. Среди таких типов выделяют типы данных с прямым, индексным и последовательным доступом. ***Тип данных с прямым доступом*** позволяет выбирать элемент непосредственно, не обращаясь сначала к предшествующим элементам в списке. Для ***типа данных с индексным доступом*** с записью данных связывается некоторый ключ, использующийся для доступа к записи. ***Типы данных с последовательным доступом*** являются динамическими структурами и характеризуются следующими свойствами:

- непостоянством и непредсказуемостью размера;
- отсутствием физической смежности элементов структуры в памяти.

Пример. Зададим простые типы данных "специальность", "студент", "вуз" следующим перечислением:

- специальность = (филолог, историк, математик, медик);
- студент = (Петров, Николаев, Семенов, Иванова, Петрова);
- вуз = (КФУ, МГУ, СевНТУ).

Значением типа "студент" может быть Петров. Опишем структурированный тип данных "специальность_студента":

- специальность_студента = (специальность, студент).

Значением типа "специальность_студента" может быть пара (историк, Семенов).

Типы данных нелинейной структуры определяют элементы без позиционного упорядочивания. Они могут иметь иерархическую или групповую структуру. ***Иерархическая структура*** – это совокупность элементов, которые разделяются по уровням, при этом элементы на данном уровне структуры могут иметь несколько наследников на следующем уровне.

Пример. Структуру "вуз" можно задать иерархической структурой, состоящей, например, из следующих уровней:

- ректорат
- деканаты и подразделения кафедры
- отделы
- преподаватели и сотрудники, студенты

Групповая структура представляет собой нелинейную структуру, которая содержит элементы без какого-либо упорядочения. Общая классификация типов данных приведена на рис. 2.1.

Рассмотрим особенности некоторых конкретных структур данных, определенных в рамках данной классификации.

Массив – это линейная структура данных, состоящая из конечного, фиксированного и упорядоченного набора элементов, имеющих один и тот же тип, с прямым доступом посредством целого индекса – номера элемента в последовательности. Для доступа к элементу на логическом уровне достаточно указать имя массива и индекс элемента.

Пример. Последовательность чисел 89, –65, 9, 0, –1.7 может образовывать одномерный вещественный массив размерности 5, например, с именем x вида: x[1] = 89, x[2] = –65, x[3] = 9, x[4] = 0, x[5] = –1.7. Значение

порядкового номера элемента массива называется индексом элемента. Можно ссылаться на элемент x[4], элемент x[i], элемент x[4+j] массива x. При текущих значениях переменных i = 2 и j = 1 эти индексы определяют, соответственно, 4-й, 2-й и 5-й элементы массива.

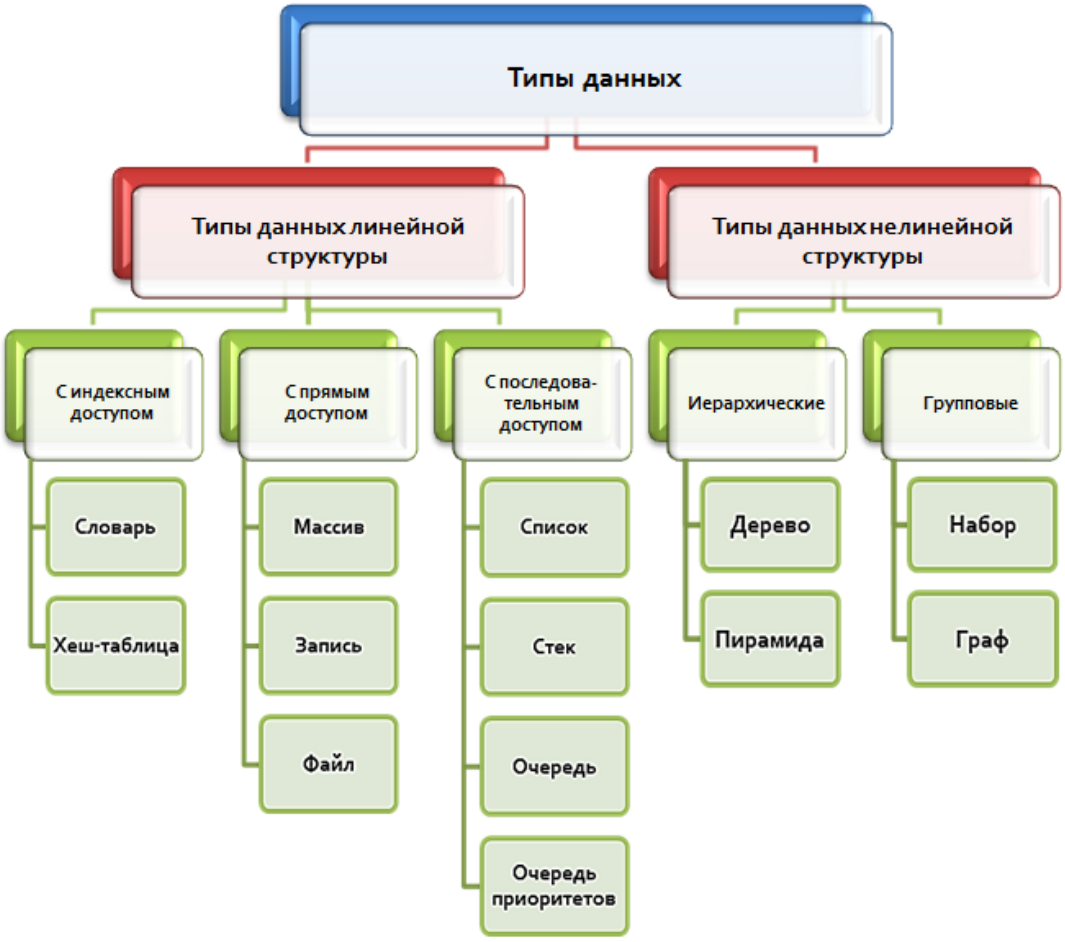


Рис. 2.1. Классификация типов данных по характер упорядоченности

Запись (структура) – это тип данных линейной структуры, содержащий конечный и фиксированный набор элементов (полей), возможно, имеющих различные типы, с прямым доступом к элементу посредством имени поля. Для доступа к полю структуры на логическом уровне достаточно указать имя структурной переменной и имя ее поля.

Словарь (таблица) – это тип данных линейной структуры с индексным доступом, состоящий из элементов вида "ключ – значение", называемых

ассоциациями. Например, ключом может быть слово, а значением – строка, указывающая определение слова. По значению в ассоциации осуществляется прямой доступ с использованием ключа в качестве индекса. В результате словарь подобен массиву, за исключением того, что индексы не должны быть целыми значениями.

Хеш-таблица – это тип данных линейной структуры с индексным доступом, предназначенный для хранения данных, связанных с ключом, который трансформируется в целый индекс, используемый для нахождения данных. Ключ необязательно должен быть целым числом, например, в качестве ключа может использоваться имя.

> **Хеш-табли́ца** — это структура данных, реализующая интерфейс ассоциативного массива, а именно, она позволяет хранить пары (ключ, значение) и выполнять три операции: операцию добавления новой пары, операцию поиска и операцию удаления пары по ключу.
>
> *https://ru.wikipedia.org*

Список – это линейная динамическая структура данных с последовательным доступом, содержащая произвольное число элементов, размер которой изменяется добавлением или удалением элемента, причем первый элемент находится в голове или в начале списка, последний элемент находится в конце списка и каждый элемент, за исключением первого и последнего, имеет единственный предыдущий и последующий элемент.

> В информатике, **спи́сок** (англ. *list*) — это абстрактный тип данных, представляющий собой упорядоченный набор значений, в котором некоторое значение может встречаться более одного раза. Экземпляры значений, находящихся в списке, называются **элементами** списка (англ. *item*, *entry* либо *element*); если значение встречается несколько раз, каждое вхождение считается отдельным элементом.
>
> *https://ru.wikipedia.org*

Стек – это список, элементы которого добавляются и удаляются только в один конец, называемый вершиной (последний пришел – первый ушел).

> **Стек** (англ. *stack* - стопка) - структура данных, представляющая собой список элементов, организованных по принципу *LIFO* (англ. *last in — first out*, «последним пришёл - первым вышел»).

> Чаще всего принцип работы стека сравнивают со стопкой тарелок: чтобы взять вторую верху, нужно снять верхнюю.
>
> В цифровом вычислительном комплексе стек называется магазином — по аналогии с магазином в огнестрельном оружии (стрельба начнётся с патрона, заряженного последним).
>
> *https://ru.wikipedia.org*

Очередь – это список с доступом только в начале и в конце этой структуры, причем элементы вставляются в конец списка и удаляются из начала (первый пришел – первый ушел).

> **О́чередь** — структура данных с дисциплиной доступа к элементам «первый пришёл — первый вышел» (FIFO, First In — First Out). Добавление элемента (принято обозначать словом enqueue — поставить в очередь) возможно лишь в конец очереди, выборка — только из начала очереди (что принято называть словом dequeue — убрать из очереди), при этом выбранный элемент из очереди удаляется. ***Очередь приоритетов*** – это список типа очередь; при удалении объекта из списка определяется элемент с наивысшим приоритетом.
>
> *https://ru.wikipedia.org*

Файл – это тип данных линейной структуры с прямым или последовательным доступом, представляющий собой последовательность байтов, приравниваемую к потоку (последовательность байтов, перемещаемая от одного устройства к другому). Прямой доступ осуществляется только к дисковому файлу.

> **Файл** (англ. *file*) — именованная область данных на носителе информации.
>
> *https://ru.wikipedia.org*

Дерево – это нелинейная иерархическая структура данных, в которой все элементы происходят от одного источника, называемого корнем. Каждый элемент, за исключением корня, имеет единственного предка.

> **Дерево** — одна из наиболее широко распространённых структур данных в информатике, эмулирующая древовидную структуру в виде набора связанных узлов.
>
> *https://ru.wikipedia.org*

Пирамида – это особый вид дерева, в котором самый маленький (большой) элемент всегда занимает корневой узел.

Набор (множество) – это нелинейная групповая структура данных, которая находит применение, когда данные являются неупорядоченными, и каждый элемент данных является единственным в своем роде, уникальным.

> **Множество** — тип и структура данных в информатике, является реализацией математического объекта множество.
>
> Данные типа множество позволяют хранить ограниченное число значений определённого типа без определённого порядка. Повторение значений, как правило, недопустимо.
>
> *https://ru.wikipedia.org*

Граф – это нелинейная групповая структура данных, задающая набор вершин и набор связей, соединяющих вершины.

Данные в структурах обрабатываются посредством некоторых операций. Выбор структуры данных зависит от частоты, с которой выполняются некоторые операции. Важную роль при обработке данных играют следующие операции:

- обход структуры: доступ к каждому элементу структуры с целью его последующей обработки;
- поиск: нахождение места расположения элемента с данным значением;
- вставка: включение нового элемента в структуру;
- удаление: исключение элемента из структуры.

Как уже было отмечено выше, рассмотрение структуры данных без учета ее представления в машинной памяти называется *абстрактной* или *логической* структурой. В общем случае между логической и соответствующей ей физической структурами существует различие, степень которого зависит от самой структуры и особенностей той среды, в которой она должна быть отражена. Вследствие этого различия существуют процедуры, осуществляющие отображение логической структуры в физическую и, наоборот, физической структуры в логическую. Эти процедуры обеспечивают, кроме того, доступ к физическим структурам и

выполнение над ними различных операций, причем каждая операция рассматривается применительно к логической или физической структуре данных. Кроме того, в зависимости от размещения физических структур, а соответственно, и доступа к ним, различают *внутренние* (находятся в оперативной памяти) и *внешние* (на внешних устройствах) структуры данных. На рис.2.2 приведена классификация структур данных в зависимости от размещения физических структур.

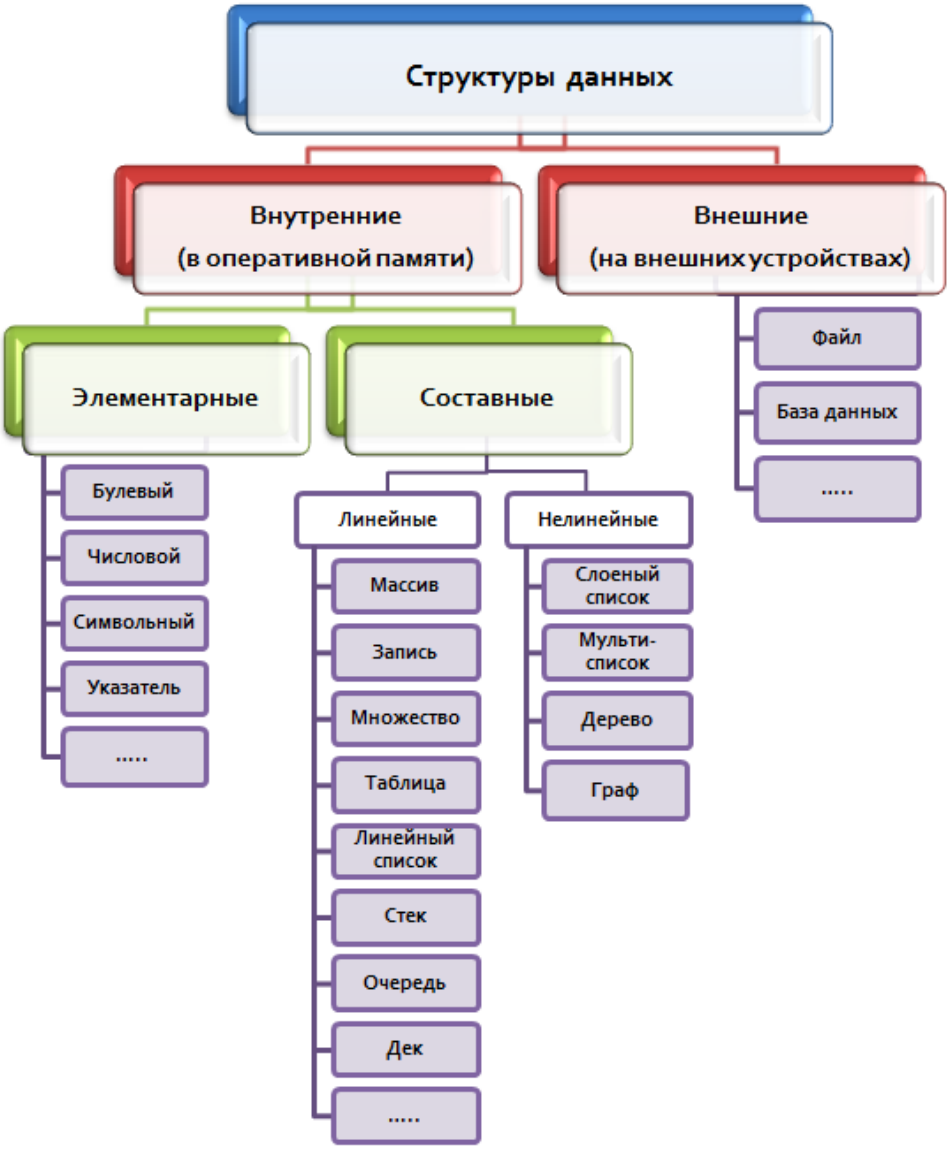


Рис. 2.2. Классификация структур данных в зависимости от размещения физических структур и доступа к ним

В рамках данной классификации различаются элементарные (простые, базовые, примитивные) структуры данных и составные (интегрированные, композитные, сложные). *Элементарными* называются такие структуры данных, которые не могут быть расчленены на составные части, большие, чем биты. С точки зрения физической структуры важным является то обстоятельство, что в конкретной машинной архитектуре, в конкретной системе программирования всегда можно заранее сказать, каков будет размер элементарного данного и каково его размещение в памяти. С логической точки зрения элементарные данные являются неделимыми единицами.

Составными называются такие структуры данных, составными частями которых являются другие структуры данных – элементарные или в свою очередь составные. Составные структуры данных конструируются программистом с использованием средств интеграции данных, предоставляемых языками программирования.

В языках программирования понятие «структуры данных» тесно связано с понятием «типы данных». Любые данные, т.е. константы, переменные, значения функций или выражения, характеризуются своими типами.

Информация по каждому типу однозначно определяет:

- структуру хранения данных указанного типа, т. е. выделение памяти, представление данных в ней и метод доступа к данным;
- множество допустимых значений, которые может иметь тот или иной объект описываемого типа;
- набор допустимых операций, которые применимы к объекту описываемого типа.

В последующих разделах рассматриваются структуры данных и соответствующие им типы данных. Базы данных детально изучаются в рамках отдельных дисциплин, и здесь рассматриваться не будут.

Вопросы для повторения темы 1

1. Какие этапы включает процесс создания компьютерной программы для решения практической задачи?
2. В чем заключается постановка задачи для решения ее на ЭВМ?
3. Что такое математическая модель?
4. Что такое алгоритм?
5. Какими свойствами должен обладать алгоритм?
6. Какие средства описания алгоритмов вы знаете?
7. В чем заключается кодирование, тестирование и отладка программы?
8. Что такое данные и структуры данных?
9. Какие уровни представления структур данных вы знаете?
10. Что такое тип данных?
11. Как соотносятся понятия "Данные", "Структура данных" и "Тип данных"?
12. Что такое базовый тип данных?
13. Что такое базовая структура данных?
14. Какие виды структур данных вы знаете?